

# Отчёт по лабораторной работе 1

*Автор работы: Писарева Юлия Игоревна, 311525*

## **Оценка частоты сердечных сокращений по видеоданным с использованием методов машинного и глубокого обучения**

В работе исследуется задача предсказания частоты сердечных сокращений (Heart Rate, HR) по видеозаписям лиц людей. В качестве исходных данных используется набор видео разных испытуемых, записанных в разных сессиях и из разных источников. Для каждого видео доступны эталонные значения HR и SpO2 по секундам. В рамках данной работы целевой переменной выбран HR.

Основная цель экспериментов – построить воспроизводимый пайплайн обработки видеоданных, извлечь признаки из областей лица и сравнить несколько подходов: простые RGB-признаки, rPPG/POS-признаки, классические регрессионные модели и модель глубокого обучения 1D CNN.

### **Оглавление**

|                                                                    |    |
|--------------------------------------------------------------------|----|
| 1. Постановка задачи .....                                         | 2  |
| 2. Описание данных и предобработка.....                            | 2  |
| 3. Методика обработки видео .....                                  | 4  |
| 4. Проведённые эксперименты .....                                  | 6  |
| 4.1. Контрольный эксперимент с wave.csv и 1D CNN.....              | 6  |
| 4.2. Базовая модель на RGB-признаках .....                         | 7  |
| 4.3. Расширенные RGB-признаки.....                                 | 8  |
| 4.4. Основной эксперимент: source2, rPPG/POS и ExtraTrees.....     | 9  |
| 4.5. Подбор параметров и дополнительные признаки.....              | 10 |
| 4.6. Объединение нескольких источников .....                       | 11 |
| 4.7. Deep Learning эксперимент: 1D CNN по rPPG/green-сигналам..... | 12 |
| 5. Сравнение результатов .....                                     | 13 |
| 6. Итоговые выводы .....                                           | 13 |
| Приложение. Использованные файлы и результаты .....                | 15 |

## 1. Постановка задачи

Практическое задание формулируется как разработка модели, способной предсказывать значения Oxygen Saturation или Heart Rate по видеоданным. Методика предполагает предобработку видео, выделение лица, поиск областей интереса, преобразование видео в последовательность кадров или сигнал, обучение модели и оценку качества по метрикам MAE и RMSE.

В данной реализации задача сведена к регрессии значения HR. Выбор HR обусловлен тем, что изменение интенсивности пикселей на участках кожи лица может быть связано с пульсовыми изменениями кровотока. Это позволяет извлекать rPPG-сигнал и использовать его для обучения регрессионных моделей.

## 2. Описание данных и предобработка

Структура данных имеет иерархический вид: группы испытуемых, отдельные участники, сессии записи и источники видео. В каждой папке source доступны файлы video.avi, gt\_HR.csv, gt\_SpO2.csv, time.txt и wave.csv. Основные эксперименты проводились для source2, так как на нём была получена лучшая устойчивость признаков и моделей.



Рисунок 1 – Структура проекта, описание данных



Рисунок 2 – Общий пайплайн обработки видеоданных




Рисунок 3 – Проверка корректного цветового пространства BGR/RGB

На первом этапе была выполнена проверка загрузки видео и корректности цветового пространства. OpenCV считывает кадры в формате BGR, поэтому для визуализации и дальнейшей обработки кадры преобразовывались в RGB.




Рисунок 4 – Пример выбранной области интереса на лбу

Для базового варианта использовалась вручную выбранная область лба. В дальнейшем пайплайн был расширен: лицо выделялось автоматически с помощью Haar Cascade, после чего из bounding box лица извлекались три ROI: лоб, левая щека и правая щека.




Рисунок 5 – Сигналы с разных участков

### 3. Методика обработки видео

Были реализованы два уровня признаков. Первый уровень – простые статистики RGB-сигнала: средние значения и стандартные отклонения каналов R, G и B за каждую секунду или временное окно. Второй уровень – rPPG-признаки, полученные с помощью POS-алгоритма. Для этого из ROI извлекались RGB-трассы, затем выполнялась фильтрация в диапазоне частот, соответствующем физиологически допустимому диапазону пульса.




Рисунок 6 – Нормализованный RGB-сигнал, извлечённый из ROI

Для экспериментов с rPPG сигнал разбивался на окна длительностью 10 секунд. Для каждого окна рассчитывались статистические и частотные признаки: среднее, стандартное отклонение, минимум, максимум, квантили, асимметрия, эксцесс, доминирующая частота в BPM и относительная мощность пика.




Рисунок 7 – Распределение значений HR в сформированном датасете

## 4. Проведённые эксперименты

### 4.1. Контрольный эксперимент с wave.csv и 1D CNN

Первый эксперимент использовал готовый физиологический сигнал из файла wave.csv. Этот вариант не является основным решением по видео, но полезен как контрольный эксперимент: он показывает, что при наличии более чистого сигнала нейросетевая модель 1D CNN способна достичь меньшей ошибки.




Рисунок 8 – Пример wave-сигнала и соответствующих значений HR




Рисунок 9 – Кривые обучения 1D CNN на wave-сигнале




Рисунок 10 – Предсказания 1D CNN на тестовой выборке для wave-сигнала

В этом варианте была получена ошибка Test MAE = 4.60 BPM и Test RMSE = 6.24 BPM. Однако данный эксперимент не считается основным, поскольку входом является уже подготовленный сигнал, а не признаки, напрямую извлечённые из видео.

#### 4.2. Базовая модель на RGB-признаках

В базовом варианте видео преобразовывалось в RGB-сигнал из области лба. Для каждой секунды рассчитывались простые статистики: R\_mean, G\_mean, B\_mean, R\_std, G\_std, B\_std. Затем обучалась модель RandomForestRegressor.




Рисунок 11 – Базовая модель на RGB-признаках при случайном разделении строк




Рисунок 12 – Базовая модель при разделении по видео

Случайное разделение строк дало  $MAE = 5.88$  BPM и  $RMSE = 9.06$  BPM, но такой вариант менее строгий, потому что окна одного видео могут оказаться и в train, и в test. При разделении по видео ошибка выросла до  $MAE = 11.41$  BPM и  $RMSE = 14.70$  BPM. Это показало необходимость более информативных признаков.

### 4.3. Расширенные RGB-признаки

На следующем этапе к базовым RGB-признакам были добавлены минимум, максимум, медиана и размах по каждому каналу. Результат почти не изменился:  $MAE = 11.38$  BPM,  $RMSE = 15.01$  BPM. Это означает, что простые статистики яркости лица недостаточно устойчивы для оценки HR на новых видео.



|   | R_mean     | G_mean     | B_mean     | R_std    | G_std    | B_std    | R_min      | G_min      | B_min      | R_max    |
|---|------------|------------|------------|----------|----------|----------|------------|------------|------------|----------|
| 0 | 193.968471 | 152.903638 | 122.654154 | 0.247262 | 0.183058 | 0.123834 | 193.521458 | 152.670000 | 122.398646 | 194.3455 |
| 1 | 194.188146 | 152.447896 | 122.433596 | 0.212448 | 0.169379 | 0.189373 | 193.731771 | 152.126771 | 122.118000 | 194.5797 |
| 2 | 194.310279 | 152.412496 | 122.395579 | 0.129924 | 0.246827 | 0.188507 | 194.063854 | 152.028958 | 122.079583 | 194.6461 |
| 3 | 194.864583 | 153.045700 | 122.518183 | 0.170575 | 0.148566 | 0.154117 | 194.607812 | 152.679062 | 122.208229 | 195.2056 |
| 4 | 195.099708 | 153.672892 | 122.720275 | 0.159541 | 0.163049 | 0.217895 | 194.732917 | 153.361771 | 122.388229 | 195.3734 |

MAE with extended features: 11.376011904761905

RMSE with extended features: 15.005365174755921

Рисунок 13 – Добавленные признаки

#### 4.4. Основной эксперимент: source2, rPPG/POS и ExtraTrees

Основной эксперимент был выполнен для одного источника source2, что соответствует условию задания о работе с видео из одного источника. Использовались три ROI лица, POS-алгоритм для извлечения rPPG-сигнала, частотные признаки и модели ExtraTrees, RandomForest, HistGradientBoosting. Разделение выполнялось по сессиям.




Рисунок 14 – Сравнение моделей для source2 на rPPG/POS-признаках

| Модель               | MAE  | RMSE  | < 5 BPM, % | < 10 BPM, % |
|----------------------|------|-------|------------|-------------|
| Baseline mean        | 9.53 | 12.63 | 35.84      | 67.43       |
| ExtraTrees           | 8.08 | 10.78 | 40.62      | 71.83       |
| HistGradientBoosting | 8.68 | 11.45 | 38.50      | 66.74       |
| RandomForest         | 8.78 | 11.85 | 39.10      | 69.02       |

Лучший результат показала модель ExtraTreesRegressor: MAE = 8.08 BPM и RMSE = 10.78 BPM. Она превзошла baseline по всем основным метрикам, поэтому этот эксперимент выбран как основной итоговый вариант.

|   | Model                | MAE      | RMSE      | < 5 BPM, % | < 10 BPM, % |
|---|----------------------|----------|-----------|------------|-------------|
| 0 | ExtraTrees           | 8.078656 | 10.775835 | 40.622627  | 71.829916   |
| 1 | HistGradientBoosting | 8.675695 | 11.453503 | 38.496583  | 66.742597   |
| 2 | RandomForest         | 8.784488 | 11.852388 | 39.104024  | 69.020501   |
| 3 | Baseline mean        | 9.332491 | 12.633920 | 35.839028  | 67.425968   |

Рисунок 15 – Вывод результатов оценки моделей для Source 2

#### 4.5. Подбор параметров и дополнительные признаки

Была выполнена дополнительная попытка улучшения: добавлены агрегированные признаки по peak\_bpm и peak\_ratio, отношения RGB-каналов, признаки согласованности между ROI, а также проведён подбор гиперпараметров ExtraTrees. Однако результат ухудшился: MAE = 8.20 BPM и RMSE = 10.99 BPM. Поэтому tuned-вариант не был выбран как финальный.

```

7 rmse_peak = np.sqrt(mean_squared_error(dataset_df["target_HR"], dataset_df[col]))
8 print(col, "MAE:", mae_peak, "RMSE:", rmse_peak)
✓ [16] 15ms

['forehead_rppg_peak_bpm', 'forehead_green_peak_bpm', 'left_cheek_rppg_peak_bpm', 'left_cheek_green_peak_bpm',
 'right_cheek_rppg_peak_bpm', 'right_cheek_green_peak_bpm']
forehead_rppg_peak_bpm MAE: 18.573902587752993 RMSE: 25.21513912914731
forehead_green_peak_bpm MAE: 23.209470884239394 RMSE: 28.830615689527086
left_cheek_rppg_peak_bpm MAE: 19.70838848510852 RMSE: 25.581439628885754
left_cheek_green_peak_bpm MAE: 21.478472680408984 RMSE: 27.20199648463738
right_cheek_rppg_peak_bpm MAE: 20.244527975049138 RMSE: 26.442908310121357
right_cheek_green_peak_bpm MAE: 20.889386655907277 RMSE: 26.981855813757534

```

Рисунок 16 – Сравнение предыдущего лучшего результата и tuned ExtraTrees




Рисунок 17 – Предсказания на тестовой выборке для source 2

#### 4.6. Объединение нескольких источников

Также был проведён эксперимент на объединённых данных из нескольких источников с разделением по сессиям. Целью было проверить устойчивость подхода при большем разнообразии данных. Лучшая модель ExtraTrees показала  $MAE = 9.70$  BPM и  $RMSE = 12.44$  BPM, что хуже результата source2, но всё ещё лучше baseline.

| Модель               | MAE   | RMSE  | < 5 BPM, % | < 10 BPM, % |
|----------------------|-------|-------|------------|-------------|
| ExtraTrees           | 9.70  | 12.44 | 34.79      | 59.62       |
| Voting ensemble      | 9.81  | 12.67 | 35.06      | 59.25       |
| HistGradientBoosting | 10.08 | 12.98 | 33.06      | 58.11       |
| RandomForest         | 10.38 | 13.82 | 34.91      | 58.57       |
| Baseline mean        | 10.61 | 13.46 | 28.94      | 54.11       |

Снижение качества объясняется различиями между источниками записи: освещение, цветопередача, положение лица, качество детекции ROI и шумы gPPG-сигнала отличаются сильнее, чем внутри одного source.

#### 4.7. Deep Learning эксперимент: 1D CNN по rPPG/green-сигналам

Для проверки подхода глубокого обучения была реализована модель 1D CNN. На вход подавались окна длительностью 10 секунд, приведённые к 250 временным точкам. Каждый пример имел 6 каналов: rPPG и green-сигнал для лба, левой щеки и правой щеки.



Рисунок 18 – Схема архитектуры 1D CNN




Рисунок 19 – Сравнение 1D CNN с baseline и ExtraTrees

| Модель        | MAE  | RMSE  | < 5 BPM, % | < 10 BPM, % |
|---------------|------|-------|------------|-------------|
| Baseline mean | 9.33 | 12.63 | 35.84      | 67.43       |
| 1D CNN        | 9.41 | 12.67 | 35.38      | 66.06       |
| ExtraTrees    | 8.08 | 10.78 | 40.62      | 71.83       |

1D CNN была успешно обучена, однако не превзошла baseline и ExtraTrees. Её MAE составила 9.41 BPM, RMSE – 12.67 BPM. По графикам обучения видно, что модель обучается, но качество на валидации стабилизируется около 9–10 BPM. Это показывает, что ограничение связано не только с архитектурой модели, но и с качеством извлечённого сигнала и объёмом данных.

## 5. Сравнение результатов




Рисунок 20 – Сводное сравнение MAE и RMSE по всем экспериментам

| Эксперимент                                | MAE   | RMSE  | Комментарий                          |
|--------------------------------------------|-------|-------|--------------------------------------|
| Wave.csv + 1D CNN, контрольный эксперимент | 4.60  | 6.24  | использует готовый wave-сигнал       |
| RGB-признаки, случайное разделение         | 5.88  | 9.06  | менее строгий split                  |
| RGB-признаки, разделение по видео          | 11.41 | 14.70 | честнее, но хуже                     |
| Расширенные RGB-признаки                   | 11.38 | 15.01 | существенного улучшения нет          |
| rPPG/POS source2 + ExtraTrees              | 8.08  | 10.78 | лучший основной вариант              |
| rPPG/POS source2 + tuned ExtraTrees        | 8.20  | 10.99 | подбор параметров не улучшил         |
| Несколько sources + ExtraTrees             | 9.70  | 12.44 | устойчивость ниже из-за domain shift |
| rPPG/POS source2 + 1D CNN                  | 9.41  | 12.67 | DL реализован, но уступил ExtraTrees |

Наиболее показательным для задания является эксперимент source2 + rPPG/POS + ExtraTrees, поскольку он использует видео из одного источника, выполняет обработку лица и ROI, преобразует видео в сигнал, обучает регрессионную модель и оценивает качество по MAE и RMSE.

## 6. Итоговые выводы

В ходе работы был реализован полный пайплайн оценки HR по видеоданным: загрузка видео, выделение лица, извлечение областей интереса, формирование

RGB- и rPPG-сигналов, построение признаков, обучение моделей и оценка результатов. Были рассмотрены как классические модели машинного обучения, так и модель глубокого обучения 1D CNN.

Лучший основной результат был получен на данных source2 с использованием rPPG/POS-признаков и модели ExtraTreesRegressor: MAE = 8.08 BPM, RMSE = 10.78 BPM. Модель превзошла baseline, что подтверждает информативность извлечённых признаков.




Рисунок 21 – Предсказания на тестовой выборке source 4, при смешанном обучении

Модель 1D CNN была реализована как deep learning-подход и обучалась на последовательностях rPPG/green-сигналов. Однако её качество оказалось близким к baseline и ниже, чем у ExtraTrees. Это показывает, что на текущем объёме и качестве данных инженерные признаки в сочетании с ансамблем деревьев оказались устойчивее, чем нейросетевая модель.

Дополнительные эксперименты показали, что смешивание разных источников ухудшает качество, вероятно из-за различий в условиях съёмки и характеристиках видео. Для дальнейшего улучшения можно использовать более точную детекцию лица и landmarks, стабилизацию ROI, оценку качества rPPG-сигнала, более крупный обучающий набор и архитектуры CNN-LSTM или Transformer по последовательностям кадров.

## **Приложение. Используемые файлы и результаты**

В ходе работы были использованы Jupyter Notebook-файлы с простым и расширенным вариантами обработки, а также итоговый ноутбук с экспериментами.

Основные численные результаты сохранены в CSV-файлы:

- model\_results\_source2.csv,
- improved\_results\_source2\_engineered.csv,
- results\_group\_split\_all\_collected.csv,
- deep\_learning\_comparison\_results.csv.