

Лабораторная работа 2

Оглавление

Лабораторная работа 2	1
Изучение методов извлечения и анализа текстовых данных	2
Цель работы	2
Задание	2
1. OCR-распознавание текста	2
2. Постобработка и очистка текста.....	4
3. Оценка качества OCR.....	5
4. Извлечение именованных сущностей с помощью готовых NER-моделей.....	6
5. Сравнение результатов SpaCy и Stanza	7
6. Расчёт метрик качества	10
7. Визуализация найденных сущностей	11
8. Разделение данных на обучающую и тестовую выборки.....	11
9. Дообучение модели NER.....	12
10. Сравнение базовой и дообученной модели.....	13
11. Использование LLM: zero-shot и few-shot prompting	14
12. Итоговое сравнение подходов	15
Вывод.....	16

Изучение методов извлечения и анализа текстовых данных

Цель работы

Целью лабораторной работы является изучение методов извлечения и анализа текстовых данных с использованием OCR-распознавания, моделей NER, дообучения модели и больших языковых моделей. В ходе работы необходимо получить текст из PDF-документа, выполнить его очистку, выделить именованные сущности, сравнить несколько подходов к их извлечению и оценить качество полученных результатов.

Задание

В рамках лабораторной работы необходимо выполнить следующие этапы:

1. Выполнить OCR-распознавание текста из предоставленного PDF-документа.
2. Провести постобработку и очистку распознанного текста.
3. Оценить качество OCR-распознавания и привести примеры ошибок.
4. Применить готовые модели NER для выделения именованных сущностей в тексте.
5. Сравнить результаты работы как минимум двух NER-моделей.
6. Рассчитать метрики качества, в том числе F1-score.
7. Выполнить визуализацию найденных сущностей в тексте.
8. Разделить размеченные данные на обучающую и тестовую выборки в пропорции 80/20.
9. Дообучить выбранную модель NER на обучающей выборке.
10. Сравнить качество дообученной модели с базовой моделью.
11. Провести эксперименты с большими языковыми моделями в режимах zero-shot и few-shot prompting.
12. Сравнить результаты OCR, NER, fine-tuning и LLM-подходов по точности, трудозатратам и практической применимости.

1. OCR-распознавание текста

На первом этапе было выполнено OCR-распознавание предоставленного PDF-документа. Для этого PDF-файл был предварительно преобразован в изображения страниц, после чего к ним был применён OCR-движок Tesseract. Распознавание выполнялось с поддержкой русского и английского языков, так как в тексте могли встречаться русскоязычные фрагменты, англоязычные термины, аббревиатуры и технические обозначения.

В работе использовались следующие инструменты:

Инструмент	Назначение
Tesseract OCR	Распознавание текста на изображениях

СОДЕРЖАНИЕ

ПОСТАНОВКА ЗАДАЧИ иининининни 2

1 Описание объекта исследования нинининининия 2

1.1 Предметная область иининининининия 3

2 Постановка задачи иинининенни 3

2.1 Цели и задачи ненененьниния 3

3 Выводы о применимости результатов нинининия 4

ТЕОРЕТИЧЕСКОЕ ИССЛЕДОВАНИЕ нининине 5

4 Цель и задачи теоретического исследования инь иининини 5

4.1 Цель ненененьнини 5

4.2 Задачи нининененинининия 5

5 Результаты теоретического исследования и иининининининининия 5

6 Выводы о применимости результатов нинининия 7

ПРАКТИЧЕСКОЕ ИССЛЕДОВАНИЕ нининининни 8

7 Возможность использования алгоритма в низком поле 9

8 Обучающая реализация алгоритма нин нининье 9

9 Реализация алгоритма как функция сервиса реконструкции

томографа 1,5 Тл нининининининье 10

1] Источники_ ии ии нининининь 11

ПОСТАНОВКА ЗАДАЧИ

1 Описание объекта исследования

Процесс исследования МРТ очень продолжительный во времени, потому что для получения изображения необходимо собрать большое количество данных частотного кодирования. Для получения этих данных производят многократные возбуждающие импульсы, которые направляют спин в нужной для исследования ориентации. Для возвращения состояния в исходное положение так же нужно время. Такие импульсы собирают в последовательности и многократно повторяют, получается набор данных, из которых и строится К-пространство (частотное пространство изображения), а затем МРТ изображение.

Рисунок 2 – Текст с очисткой

2. Постобработка и очистка текста

После OCR-распознавания была выполнена постобработка текста. Необходимость данного этапа связана с тем, что результат автоматического распознавания часто содержит лишние пробелы, переносы строк, случайные символы, искажённые слова и фрагменты, появившиеся из-за распознавания рисунков или таблиц.

В ходе очистки были выполнены следующие действия:

Этап обработки	Выполненное действие	Результат
Удаление лишних пробелов	Убраны повторяющиеся пробелы и табуляции	Текст стал более читаемым

Нормализация переносов строк	Удалены лишние пустые строки	Улучшена структура текста
Удаление мусорных строк	Убраны строки из отдельных символов и случайных наборов знаков	Снижено количество OCR-шума
Исправление частых ошибок	Выполнены ручные замены повторяющихся ошибок OCR	Повышено качество текста
Сохранение результата	Очищенный текст сохранён в отдельный файл	Текст подготовлен для дальнейшего анализа

После обработки был получен очищенный текст, пригодный для дальнейшего извлечения именованных сущностей.

	Этап	Описание	Длина текста
0	Исходный OCR-текст	Текст, полученный напрямую после OCR-распознав...	13532
1	После базовой очистки	Удалены лишние пробелы, табуляции и лишние пер...	13441
2	После удаления мусорных строк	Удалены короткие и служебные строки, не несущи...	13427
3	После исправления частых ошибок	Исправлены повторяющиеся ошибки распознавания	13427

Рисунок 3 – Показано как менялось количество текста после чистки

3. Оценка качества OCR

На следующем этапе была проведена оценка качества OCR-распознавания. Для этого распознанный текст был визуально сопоставлен с исходным PDF-документом. Особое внимание уделялось фрагментам, где встречались технические термины, английские слова, аббревиатуры и подписи к рисункам.

В ходе анализа были выявлены типичные ошибки OCR:

Фрагмент OCR	Правильный вариант	Тип ошибки	Комментарий
`paraПе	parallel imaging	Смесь русского и английского	Неверное распознавание английского текста
СКАРРА	GRAPPA	Ошибка распознавания аббревиатуры	OCR неверно распознал название алгоритма
AC3	ACS	Ошибка распознавания латинских символов	Английская аббревиатура была заменена похожими кириллическими буквами

возбуждающих	возбуждающих	Лишний символ	Ошибка внутри русского слова
К-пространство	К-пространство	Распознано корректно	Термин был сохранён правильно

По результатам оценки можно сделать вывод, что OCR позволил получить читаемый текст, однако некоторые технические обозначения и англоязычные термины были распознаны с ошибками. Это подтверждает необходимость последующей очистки и ручной проверки текста перед использованием его в задачах анализа.

4. Извлечение именованных сущностей с помощью готовых NER-моделей

После подготовки текста были применены готовые модели NER для извлечения именованных сущностей. В качестве моделей были выбраны SpaCy и Stanza.

Именованные сущности — это значимые объекты в тексте, например имена людей, географические названия, организации, даты, названия произведений, а также специальные термины и обозначения.

В работе использовались следующие типы сущностей:

Тип сущности	Значение	Пример
PER / PERSON	Персона, имя человека	Ваганов Ярослав
LOC / LOCATION	Географический объект	Москва
ORG / ORGANIZATION	Организация или учреждение	Университет, Джэт лаб
DATE	Дата или временной период	2024 год, 2026 год
MISC	Прочая сущность, термин или обозначение	GRAPPA, MPT, ACS

В результате обработки текста модели выделили различные сущности. По полученным данным была составлена сравнительная таблица.

	Тип сущности	SpaCy	Stanza
0	LOC	10.0	10
1	MISC	0.0	95
2	ORG	50.0	20
3	PER	8.0	25

Рисунок 4 – Сравнительная таблица по сущностям

Цель	Текст сущности	Тип сущности	Начало	Конец	Модель	Текст сущности	Тип сущности	Начало	Конец	
Цель	Предметная область	LOC	145	163	0	Станза	СОДЕРЖАНИЕ	MISC	0	10
	BP + + + oH + + № 4+ o e\ nDx\ n\ nDx	ORG	2033	2060	1	Станза	ПОСТАНОВКА ЗАДАЧИ.	PER	12	30
Цель	PE	ORG	2119	2121	2	Станза	Описание объекта исследования	MISC	66	95
	Предметная область	LOC	2698	2716	3	Станза	Предметная область	MISC	145	163
Цель	Цель	PER	3437	3441	4	Станза	Постановка задачи	MISC	214	231
	GRAPPA	ORG	3487	3493	5	Станза	1 Цели	MISC	268	274
Цель	СКAPPA	ORG	3723	3729	6	Станза	ОО	MISC	324	326
	К-	LOC	4110	4112	7	Станза	1 Цель	MISC	543	549
Цель	MPA	ORG	4200	4203	8	Станза	4.2 Задачи	MISC	576	586
	GRAPPA	ORG	4516	4522	9	Станза	Выводы о применимости результатов	MISC	696	729
Цель	К-	LOC	4762	4764	10	Станза	7\ nПРАКТИЧЕСКОЕ ИССЛЕДОВАНИЕ	PER	758	785
	Алгоритм	ORG	4949	4957	11	Станза	Возможность использования алгоритма в низком поле	MISC	823	872
Цель	OKAPPA	ORG	4958	4964	12	Станза	9\ n8 Обучающая реализация алгоритма	MISC	891	925
	GRAPPA	ORG	5184	5190	13	Станза	Тл.	MISC	1045	1048
Цель	К-	LOC	6011	6013	14	Станза	ЗАКЛЮЧЕНИЕ	LOC	1090	1100
	СКAPPA	ORG	6513	6519	15	Станза	Источники	MISC	1297	1306
Цель	CBAPPA	ORG	7174	7180	16	Станза	ПОСТАНОВКА ЗАДАЧИ	MISC	1340	1357
	Frequency Encoding (ky)	ORG	7498	7521	17	Станза	MPT	MISC	1413	1416
Цель	Ampo	ORG	7524	7528	18	Станза	К-пространство	MISC	1876	1890
	К-	LOC	8694	8696	19	Станза	Dx	MISC	2058	2060

Модель	Тип сущности	Сущность	Контекст
0	SpaCy	LOC	Предметная область Описание объекта исследования..... ли...
1	SpaCy	ORG	BP +++ oH ++ № 4+ oe\ndx\n\ndx \n\n90x 180y 180y ,---, 180y 180y 180:\n ...
2	SpaCy	ORG	PE oH ++ № 4+ oe\ndx\n\ndx\n\ndx\tnt trl deel de...
3	SpaCy	LOC	Предметная область омостью алгоритмов.\n\n\n\n\nРисунок 2 — Пара: ...
4	SpaCy	PER	Цель лученное путем ускорения, не\n\nотличалось от ...
5	SpaCy	ORG	GRAPPA оренного».\n2.1 Цели и задачи\n\nЦель: теорети...
6	SpaCy	ORG	СКAPPA , рассмотреть этапы автокалибровки и расчёта\n...
7	SpaCy	LOC	K- компонент для сбора\nаппарата, но и с помощью ...
8	SpaCy	ORG	MPA нства. Так как программная реализация таких ал...
9	SpaCy	ORG	GRAPPA ического исследования\n\n4.1 Цель\n\nРазработа...
10	SpaCy	LOC	K- , выделить этапы в\nпроцессе реконструкции, оп...
11	SpaCy	ORG	Алгоритм модель алгоритма, разбитую на этапы.\n5 Резул...
12	SpaCy	ORG	OKAPPA лгоритма, разбитую на этапы.\n5 Результаты тео...
13	SpaCy	ORG	GRAPPA мация о том, какая исследуемая область\nупавли...
14	SpaCy	LOC	K- льсе) в\nчастотное пространство ([K]-пространс...

5. Сравнение результатов SpaCy и Stanza

Для более подробного анализа были сопоставлены сущности, найденные двумя моделями. Сравнение проводилось по следующим параметрам:

Показатель	Что показывает
Всего сущностей SpaCy	Общее количество сущностей, найденных SpaCy
Всего сущностей Stanza	Общее количество сущностей, найденных Stanza
Общие сущности	Сущности, найденные обеими моделями
Только SpaCy	Сущности, найденные только SpaCy
Только Stanza	Сущности, найденные только Stanza
Коэффициент Жаккара	Степень совпадения наборов сущностей

Количество уникальных сущностей SpaCy: 52
 Количество уникальных сущностей Stanza: 125
 Количество совпавших сущностей: 32
 Коэффициент сходства Жаккара: 0.221

Такое сравнение позволило установить, что совпадение между моделями было неполным. Часть сущностей была найдена обеими моделями, однако значительная часть объектов выделялась только одной из них. Это подтверждает, что использование разных NER-моделей может давать существенно отличающиеся результаты, особенно при обработке технического текста и текста, полученного после OCR.

	Текст сущности_SpaCy	Тип сущности_SpaCy	Тип сущности_Stanza
0	Предметная область	LOC	MISC
1	Предметная область	LOC	LOC
4	GRAPPA	ORG	MISC
11	СКАРРА	ORG	MISC
19	МРА	ORG	MISC
27	ОКАРРА	ORG	MISC
43	СВАРРА	ORG	MISC
44	Амро	ORG	MISC
45	Отарра	PER	PER
46	Епит	PER	PER
55	Ру@оп	ORG	MISC
56	ИТМО	ORG	LOC
58	НИР	ORG	ORG
67	РуФоп	PER	MISC
68	России	LOC	LOC
77	ЛаПа	ORG	MISC
78	ДЖЭТ ЛАБ	ORG	ORG
95	Нас Т.	ORG	PER
96	LaConte S.M.	ORG	PER
97	Magnetic Resonance in Medicine	ORG	MISC
99	Jakob P.M.	ORG	PER
100	Heidemann R.M.	ORG	PER
101	Nittka M.	ORG	PER

Рисунок 7 – Как определили сущности разные модели

	Текст сущности	Тип сущности	Начало	Конец
1	BP +++ oH ++ № 4+ oe\nDx\n\nDx	ORG	2033	2060
2	РЕ	ORG	2119	2121
4	Цель	PER	3437	3441
7	К-	LOC	4110	4112
10	К-	LOC	4762	4764
11	Алгоритм	ORG	4949	4957
14	К-	LOC	6011	6013
17	Frequency Encoding (ky)	ORG	7498	7521
19	К-	LOC	8694	8696
21	К-	LOC	8967	8969
23	Низкое поле	LOC	9153	9164
28	Original image Input image GRAPPA result\n\n\n...	ORG	9459	9555
35	К-	LOC	10770	10772
38	Ваганов	PER	11427	11434
39	Ярослав Сергеевич	PER	11435	11452
40	ИСУ	ORG	11454	11457
41	Ру	PER	11510	11512
42	Константин Максимович	PER	11529	11550
43	ИСУ	ORG	11552	11555
46	Hu X. Cross-validation-\nbased kernel support ...	ORG	12350	12439
48	Nunes R.G. Parallel magnetic resonance\nimaging	ORG	12518	12564
55	Haase A. Generalized autocalibrating partially	ORG	12691	12737
56	Magn Reson Med	ORG	12770	12784
59	United States Patent No	ORG	12847	12870
61	Detre J.A. Improved data reconstruction method...	ORG	12926	12983
62	ДЖЭТ-ЛАБ	ORG	13044	13052

Рисунок 8 – Сущности, которые нашла только SpaCy модель

	Текст сущности	Тип сущности	Начало	Конец
0	СОДЕРЖАНИЕ	MISC	0	10
1	ПОСТАНОВКА ЗАДАЧИ.	PER	12	30
2	Описание объекта исследования	MISC	66	95
4	Постановка задачи	MISC	214	231
5	1 Цели	MISC	268	274
6	ОО	MISC	324	326
7	1 Цель	MISC	543	549
8	4.2 Задачи	MISC	576	586
9	Выводы о применимости результатов	MISC	696	729
10	7\nПРАКТИЧЕСКОЕ ИССЛЕДОВАНИЕ	PER	758	785
11	Возможность использования алгоритма в низком поле	MISC	823	872
12	9\n8 Обучающая реализация алгоритма	MISC	891	925
13	Тл.	MISC	1045	1048
14	ЗАКЛЮЧЕНИЕ	LOC	1090	1100
15	Источники	MISC	1297	1306
16	ПОСТАНОВКА ЗАДАЧИ	MISC	1340	1357
17	MPT	MISC	1413	1416
18	К-пространство	MISC	1876	1890
19	Dx	MISC	2058	2060
20	Dy Dy\nG A	MISC	2088	2099
21	PE PE y\n02 Dz!	ORG	2119	2133
22	Gz	MISC	2139	2141
23	aot Sty Navigator	MISC	2154	2171
24	Методика получения MPT	MISC	2192	2214

Рисунок 9 – Сущности, которые нашла только Stanza модель

	Показатель	Количество
0	Всего сущностей SpaCy	68
1	Всего сущностей Stanza	150
2	Общие сущности	32
3	Только SpaCy	20
4	Только Stanza	93

Рисунок 10 – Сравнение по количеству найденных сущностей

6. Расчёт метрик качества

Для количественной оценки качества моделей были рассчитаны метрики Precision, Recall и F1-score. В качестве эталонной разметки использовался вручную проверенный фрагмент текста, содержащий технические термины и обозначения.

В эталонную разметку были включены следующие сущности:

Сущность	Тип	Пояснение
MPT	MISC	Техническая область
К-пространство	MISC	Термин из области MPT
MPT изображение	MISC	Технический термин
GRAPPA	MISC	Название алгоритма
ACS	MISC	Техническое обозначение автокалибровочных данных
MP-томографы	MISC	Технический объект

Используемые метрики имеют следующее значение:

Метрика	Значение
Precision	Доля правильно найденных сущностей среди всех сущностей, найденных моделью
Recall	Доля найденных моделью сущностей среди всех эталонных сущностей
F1-score	Обобщающая метрика, учитывающая Precision и Recall

Расчёт метрик показал, что простое количество найденных сущностей не всегда отражает качество модели. Модель может выделять много фрагментов, но часть из них может быть ошибочной. Поэтому для оценки качества важно учитывать не только количество найденных объектов, но и их совпадение с эталонной разметкой.

	Модель	True Positive	False Positive	False Negative	Precision	Recall	F1-score
0	SpaCy	0	52	8	0.000000	0.000	0.000000
1	Stanza	3	125	5	0.023438	0.375	0.044118

Рисунок 11 – Расчет метрик

7. Визуализация найденных сущностей

Для наглядного отображения результатов была выполнена визуализация найденных сущностей. Визуализация позволяет увидеть, какие именно фрагменты текста модель выделила как сущности и к каким типам она их отнесла.

Для визуализации использовался инструмент `displacy` из библиотеки `SpaCy`. Он позволяет отображать сущности непосредственно в тексте, выделяя их цветом и подписывая тип сущности.

Визуализация показала, что готовые модели достаточно хорошо справляются с некоторыми стандартными сущностями, однако специализированные технические термины могут пропускаться или классифицироваться некорректно.

```
from spacy import displacy

displacy.render(doc_base, style="ent", jupyter=True)
```

Алгоритм GRAPPA используется для восстановления MPT изображения.

Для этого применяются данные AC3 **ORG** и информация из K-пространства.

Современные МР-томографы позволяют получать изображения с помощью нескольких приемных катушек.

Методы параллельного сканирования позволяют уменьшить длительность исследования.

```
displacy.render(doc_finetuned, style="ent", jupyter=True)
```

Алгоритм GRAPPA **MISC** используется для восстановления MPT изображения **MISC**.

Для этого применяются данные AC3 **MISC** и информация из K- **MISC** пространства.

Современные MP- **MISC** томографы позволяют получать изображения с помощью нескольких приемных катушек.

Методы параллельного сканирования позволяют уменьшить длительность исследования.

Рисунок 12 – Пример визуализации

8. Разделение данных на обучающую и тестовую выборки

Для выполнения этапа дообучения данные были разделены на обучающую и тестовую выборки. В соответствии с заданием использовалась пропорция 80/20: 80% данных предназначались для обучения модели, а 20% — для проверки её качества.

Такой подход позволяет оценить, насколько хорошо модель не просто запоминает обучающие примеры, а способна применять полученные знания к новым фрагментам текста.

Выборка	Доля данных	Назначение
Обучающая	80%	Используется для дообучения модели
Тестовая	20%	Используется для проверки качества модели

В данной работе использовался небольшой вручную размеченный фрагмент технического текста. В нём были выделены специализированные сущности, относящиеся к категории MISC.

	Модель	True Positive	False Positive	False Negative	Precision	Recall	F1-score
0	Базовая SpaCy	0	1	5	0.0	0.0	0.0
1	Дообученная SpaCy	3	2	2	0.6	0.6	0.6

Рисунок 13 – Результаты обучения

9. Дообучение модели NER

На следующем этапе было выполнено дообучение модели SpaCy. Целью дообучения была адаптация модели к предметной области текста, связанной с МРТ и алгоритмами реконструкции изображений.

Для обучения были использованы сущности:

Сущность	Тип
МРТ изображения	MISC
К-пространство	MISC
МРТ изображение	MISC
GRAPPA	MISC
ACS	MISC
МР-томографы	MISC

Все эти сущности были отнесены к типу MISC, поскольку они являются техническими терминами и обозначениями, а не персонами, организациями или локациями.

В процессе дообучения были выполнены следующие действия:

Этап	Описание
Подготовка текста	Выбран фрагмент технического текста
Ручная разметка	Определены сущности и их позиции в тексте
Добавление меток	В модель добавлена метка MISC
Обучение	Модель дообучена на размеченном фрагменте

Проверка	Модель применена к тестовому тексту
----------	-------------------------------------

Дообучение позволило адаптировать модель к специализированным терминам, которые базовая модель могла не распознавать.

	Модель	Тип сущности	Количество
0	Базовая SpaCy	ORG	1
1	Дообученная SpaCy	MISC	5

	Модель	Текст сущности	Тип сущности	Начало	Конец
0	Дообученная SpaCy	GRAPPA	MISC	10	16
1	Дообученная SpaCy	MPT изображения	MISC	49	64
2	Дообученная SpaCy	AC3	MISC	95	98
3	Дообученная SpaCy	K-	MISC	115	117
4	Дообученная SpaCy	MP-	MISC	143	146

	Модель	Текст сущности	Тип сущности	Начало	Конец
0	Базовая SpaCy	AC3	ORG	95	98
1	Дообученная SpaCy	GRAPPA	MISC	10	16
2	Дообученная SpaCy	MPT изображения	MISC	49	64
3	Дообученная SpaCy	AC3	MISC	95	98
4	Дообученная SpaCy	K-	MISC	115	117
5	Дообученная SpaCy	MP-	MISC	143	146

Рисунок 14 – Результаты дообучения

10. Сравнение базовой и дообученной модели

После дообучения было выполнено сравнение базовой модели SpaCy и дообученной модели. Для этого один и тот же тестовый фрагмент был обработан двумя вариантами модели.

Сравнение проводилось по следующим параметрам:

Параметр	Описание
Количество найденных сущностей	Сколько объектов выделила модель
Типы сущностей	Какие категории были присвоены найденным объектам
Совпадение с эталоном	Насколько результат соответствует ручной разметке

F1-score	Итоговая метрика качества
----------	---------------------------

Базовая модель SpaCy ориентирована преимущественно на стандартные категории сущностей, такие как персоны, организации и локации. Поэтому специализированные термины, например GRAPPA, MPT, К-пространство, ACS, могут не выделяться или выделяться некорректно.

После дообучения модель стала лучше распознавать термины предметной области. Это показывает, что fine-tuning может быть полезен при работе с узкоспециализированными текстами.

11. Использование LLM: zero-shot и few-shot prompting

Дополнительно был проведён эксперимент с использованием больших языковых моделей. В отличие от классических NER-моделей, LLM не обучалась дополнительно, а получала задачу в виде текстовой инструкции.

Были проверены два режима:

Режим	Описание
Zero-shot prompting	Модель получает только инструкцию без примеров
Few-shot prompting	Модель получает инструкцию и несколько примеров правильной разметки

В режиме zero-shot модель получила описание типов сущностей и требуемого формата ответа. Однако результат оказался менее пригодным для автоматической обработки, так как модель не всегда строго следовала заданному формату.

В режиме few-shot в промпт были добавлены примеры правильной разметки. Это позволило модели лучше понять задачу и сформировать более структурированный ответ. В результате few-shot prompting оказался более удобным для автоматического извлечения сущностей из ответа LLM.

Примеры сущностей, выделенных LLM в режиме few-shot:

Сущность	Тип	Объяснение
GRAPPA	MISC	Название алгоритма
MPT изображение	MISC	Технический термин
ACS	MISC	Техническое обозначение автокалибровочных данных
К-пространство	MISC	Термин из области MPT
Рисунок 1	MISC	Элемент документа

Эксперимент показал, что наличие примеров в промпте повышает управляемость ответа LLM и облегчает дальнейшую автоматическую обработку результатов.

12. Итоговое сравнение подходов

На заключительном этапе было выполнено сравнение всех рассмотренных подходов. Итоговая таблица формировалась автоматически на основе результатов, полученных на предыдущих этапах: количества найденных сущностей, уникальных сущностей, типов сущностей и рассчитанных метрик качества.

Подход	Особенности	Практическая применимость
SpaCy baseline	Быстро запускается, не требует обучения	Подходит для первичного анализа текста
Stanza baseline	Хорошо работает с русскоязычным текстом, выделяет больше сущностей	Подходит для анализа текстов на русском языке
Дообученная SpaCy	Адаптируется к технической терминологии	Подходит для специализированных документов
LLM zero-shot	Не требует обучения, работает по инструкции	Удобен для быстрого эксперимента, но формат ответа нестабилен
LLM few-shot	Использует примеры и лучше следует формату	Подходит для гибкой разметки небольших текстов

Сравнение показало, что готовые NER-модели удобны для быстрого запуска, но не всегда корректно работают с узкоспециализированными терминами. Дообучение модели позволяет повысить качество распознавания терминов предметной области, однако требует подготовки размеченных данных. LLM-подход удобен тем, что не требует обучения, но его результат зависит от качества промпта и может нуждаться в дополнительной проверке.

SpaCy:
 Всего сущностей: 68
 Уникальных сущностей: 52
 Типы сущностей: LOC, ORG, PER

Базовая SpaCy:
 Всего сущностей: 1
 Уникальных сущностей: 1
 Типы сущностей: ORG

Stanza:
 Всего сущностей: 150
 Уникальных сущностей: 127
 Типы сущностей: LOC, MISC, ORG, PER

Дообученная SpaCy:
 Всего сущностей: 5
 Уникальных сущностей: 5
 Типы сущностей: MISC

Рисунок 15 – Результаты для SpaCy и Stanza

	Подход	Текст сущности	Тип сущности	Объяснение
0	LLM few-shot	GRAPPA	MISC	название алгоритма
1	LLM few-shot	MPT изображение	MISC	технический термин
2	LLM few-shot	ACS	MISC	техническое обозначение автокалибровочных данных
3	LLM few-shot	К-пространство	MISC	термин из области MPT
4	LLM few-shot	Рисунок 1	MISC	техническая диаграмма
5	LLM few-shot	MPT изображение	MISC	технический термин
6	LLM few-shot	К-пространство	MISC	термин из области MPT
7	LLM few-shot	PARA	MISC	пара (математическая концепция)
8	LLM few-shot	GRAPPA	ORG	алгоритм
9	LLM few-shot	ACS	MISC	техническое обозначение автокалибровочных данных
10	LLM few-shot	Параллельное сканирование	MISC	термин из области MPT
11	LLM few-shot	Весовые коэффициенты	MISC	термин из области MPT
12	LLM few-shot	MP-томографы	ORG	оборудование
13	LLM few-shot	приёмные катушки	MISC	технические устройства
14	LLM few-shot	различные пространственные чувствительности	MISC	термин из области MPT

	Подход	Текст сущности	Тип сущности	Объяснение
0	LLM few-shot	GRAPPA	MISC	название алгоритма
1	LLM few-shot	MPT изображение	MISC	технический термин
2	LLM few-shot	ACS	MISC	техническое обозначение автокалибровочных данных
3	LLM few-shot	К-пространство	MISC	термин из области MPT
4	LLM few-shot	Рисунок 1	MISC	техническая диаграмма

Рисунок 16 – Результаты для LLM few shot

	Подход	True Positive	False Positive	False Negative	Precision	Recall	F1-score
0	LLM zero-shot	0	0	5	0.000	0.0	0.000
1	LLM few-shot	1	11	4	0.083	0.2	0.118

Рисунок 17 – Сравнение методов LLM

	Подход	Всего найдено сущностей	Уникальных сущностей	Типы сущностей	Precision	Recall	F1-score
0	SpaCy baseline	68	52	LOC, ORG, PER	0.000	0.000	0.000
1	Stanza baseline	150	127	LOC, MISC, ORG, PER	0.023	0.375	0.044
2	Базовая SpaCy на тестовом фрагменте	1	1	ORG	0.000	0.000	0.000
3	Дообученная SpaCy	5	5	MISC	0.600	0.600	0.600

Рисунок 18 – Вывод по методам

Вывод

В ходе лабораторной работы были изучены методы извлечения и анализа текстовых данных. Сначала был выполнен OCR-анализ PDF-документа, после чего полученный текст был очищен и подготовлен для дальнейшей обработки. Анализ ошибок OCR показал, что автоматическое распознавание позволяет получить читаемый текст, но требует постобработки, особенно при наличии технических терминов, схем и англоязычных обозначений.

Далее были применены готовые NER-модели SpaCy и Stanza. Их сравнение показало, что разные модели по-разному выделяют именованные сущности. SpaCy чаще относил фрагменты к организациям, тогда как Stanza выделяла больше персоналий и

сущностей типа MISC. Это подтвердило необходимость сравнения нескольких моделей при решении задачи извлечения сущностей.

Расчёт метрик Precision, Recall и F1-score позволил оценить качество моделей количественно. Было установлено, что большое количество найденных сущностей не всегда означает высокое качество, так как модель может выделять лишние или неверно классифицированные фрагменты.

Дообучение модели SpaCy позволило адаптировать её к специализированной предметной области. После fine-tuning модель стала лучше выделять технические термины, такие как GRAPPA, MPT, ACS и К-пространство. Это показывает, что дообучение является эффективным подходом при регулярной обработке однотипных специализированных документов.

Эксперимент с LLM показал, что большие языковые модели могут использоваться для извлечения сущностей без отдельного обучения. При этом zero-shot prompting оказался менее стабильным, так как модель не всегда соблюдала требуемый формат ответа. Few-shot prompting дал более управляемый результат благодаря добавлению примеров правильной разметки.

Таким образом, для быстрого первичного анализа можно использовать готовые NER-модели или LLM в режиме zero-shot. Для небольших технических текстов удобным оказался few-shot prompting, так как он не требует обучения модели и позволяет гибко задавать правила разметки. Для массовой обработки специализированных документов наиболее обоснованным является fine-tuning NER-модели, поскольку он обеспечивает более стабильную адаптацию к предметной области.

Google Colab – тут https://github.com/zi2p/Knowledge-management/blob/main/%D0%9B%D0%A0%202/%D0%9B%D0%A0_2.ipynb